

Министерство науки и высшего образования Российской Федерации
Санкт-Петербургский политехнический университет Петра Великого
Институт машиностроения, материалов и транспорта
Высшая школа автоматизации и робототехники

Работа допущена к защите

Директор ВШАиР

_____ О.Н. Мацко

«__»_____ 2021 г.

**ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА БАКАЛАВРА
ПРОГНОЗИРОВАНИЕ ОТКАЗОВ ДАТЧИКОВ СОСТОЯНИЯ
ЖЕЛЕЗНОДОРОЖНЫХ МОСТОВ МЕТОДАМИ МАШИННОГО
ОБУЧЕНИЯ**

по направлению подготовки 15.03.06 «Мехатроника и робототехника»

направленность (профиль) 15.03.06_04 «Автономные роботы»

Выполнил

студент гр. 3331506/70401

Е.И. Чернов

Руководитель

Старший преподаватель

А.С. Габриель

Консультант

по нормоконтролю

С.Г. Чупров

Санкт-Петербург

2021

Министерство науки и высшего образования Российской Федерации
Санкт-Петербургский политехнический университет Петра Великого
Институт машиностроения, материалов и транспорта
Высшая школа автоматизации и робототехники

УТВЕРЖДАЮ

Директор ВШАиР

_____ О.Н. Мацко

« ____ » _____ 2021 г.

ЗАДАНИЕ
на выполнение выпускной квалификационной работы

студенту Чернову Евгению Ивановичу, гр. 3331506/70401

1. Тема работы: Прогнозирование отказов датчиков состояния железнодорожных мостов методами машинного обучения.

2. Срок сдачи студентом законченной работы: « ____ » _____ 2021 г.

3. Исходные данные по работе: Требования к разрабатываемому алгоритму.

4. Содержание работы (перечень подлежащих разработке вопросов): Причины отказов тензометрических датчиков; обзор подходов к прогнозированию; математическое описание метода классификации; прогнозирование отказов тензометрических датчиков.

5. Перечень графического материала (с указанием обязательных чертежей):

7. Дата выдачи задания: « ____ » _____ 2021 г.

Руководитель ВКР

_____ (подпись)

А.С. Габриель

_____ инициалы, фамилия

Консультант по нормоконтролю

_____ (подпись)

С.Г. Чупров

_____ инициалы, фамилия

Задание принял к исполнению

_____ (дата)

Студент

_____ (подпись)

Е.И. Чернов

_____ инициалы, фамилия

РЕФЕРАТ

На 49 с., 19 рисунков, 3 таблиц, 31 источников.

КЛЮЧЕВЫЕ СЛОВА: ПРОГНОЗИРОВАНИЕ, МОДЕЛЬ ОПОРНЫХ ВЕКТОРОВ, КЛАССИФИКАЦИЯ, ВРЕМЕННЫЕ РЯДЫ, ТЕНЗОРЕЗИСТИВНЫЕ ДАТЧИКИ, АНАЛИЗ ОТКАЗОВ ДАТЧИКОВ.

В данной работе будут рассматриваться отказы тензометрических датчиков. На основании возвращаемой ими величины механического напряжения можно судить о состоянии наблюдаемых сооружений, в частности мостов. Исходя из специфики наблюдения за состоянием железнодорожных мостов, при прогнозировании отказов учитываются циклические нагрузки и изменчивые погодные условия, в частности температура воздуха.

Целью данной работы является исследование возможности прогнозирования отказов тензометрических датчиков, учитывая негативное влияние температуры и циклических нагрузок.

Машинное обучение позволяет упростить процесс анализа состояния датчика, что упрощает реализацию прогнозирования отказов. Учитывая особенности отказов тензорезистивных датчиков, для прогнозирования отказов в работе используется модель классификации. При этом данные делятся на два класса: соответствующие будущей поломке и не соответствующие будущей поломке.

Из-за редкости как такового явления отказа датчика, данных из реальных систем недостаточно, чтобы построить модель классификатора. В следствие этого в ходе работы была построена модель на основании синтетического набора данных.

ABSTRACT

49 pages, 19 figures, 3 tables, 31 sources.

KEY WORDS: FORECASTING, SUPPORT VECTOR MODEL, CLASSIFICATION, TIME SERIES, STRAIN-RESISTIVE SENSORS, SENSOR FAILURE ANALYSIS.

In this paper, we will consider the failures of strain gauges. Based on the amount of mechanical stress returned by them, it is possible to judge the state of the observed structures, in particular bridges. Based on the specifics of monitoring the condition of railway bridges, cyclical loads and changeable weather conditions, in particular air temperature, are taken into account when predicting failures.

The purpose of this work is to study the possibility of predicting failures of strain gauges, taking into account the negative impact of temperature and cyclic loads.

Machine learning allows you to simplify the process of analyzing the sensor state, which simplifies the implementation of failure prediction. Taking into account the features of failures of strain-resistive sensors, a classification model is used to predict failures in operation. In this case, the data is divided into two classes: corresponding to a future failure and not corresponding to a future failure.

Due to the rarity of sensor failure as such, there is not enough data from real systems to build a classifier model. As a result, in the course of the work, a model was built on the basis of a synthetic data set.

СОДЕРЖАНИЕ

Введение.....	6
1 Причины отказов тензометрических датчиков	9
1.1 Неисправности тензометрических датчиков.....	10
1.2 Нарушение целостности моста.....	12
1.3 Выводы по разделу	15
2 Обзор подходов к прогнозированию.....	17
2.1 Обзор методов прогнозирование численного признака временного ряда.	17
2.2 Обзор методов классификации.....	19
2.3 Выводы по разделу	20
3 Математическое описание метода классификации	22
3.1 Метод опорных векторов	22
3.2 Выводы по разделу	24
4 Прогнозирование отказов тензометрических датчиков.....	25
4.1 Создание набора данных	25
4.2 Подготовка данных	36
4.3 Обучение классификатора	40
4.4 Выводы по разделу	42
Заключение	44
Список использованных источников	46

ВВЕДЕНИЕ

Любое инженерно-техническое сооружение со временем может прийти в негодность и мосты не исключение. Проводить техническое обслуживание и ремонт мостов является обычной практикой. Однако между отдельными техническими работами проходит некоторое время, в течение которого состояние сооружения может критически измениться. Для непрерывного контроля параметров инженерного объекта реализуется система мониторинга, которая подразумевает под собой наличие сети датчиков.

Мостовые сооружения могут быть как пешеходными, так и предназначаться для проложения пути сообщения транспорта. Транспорт играет важную социально-экономическую роль, коренным образом влияя на качество жизни общества. Железная дорога является одной из основных логистических инфраструктур, имея значительное влияние как на грузооборот, так и на пассажирооборот [1]. В отдельных случаях нарушение графика движения данного типа транспорта могут привести к серьезным экономическим издержкам.

В случае предельное состояние конструкций моста, а в отдельных случаях угрозы его обрушения, происходит закрытие движения по нему транспорта. В случае с железной дорогой описываемая ситуация способна вызвать существенное нарушение графика движения, что повлечет за собой экономические издержки.

Для контроля состояния на мостовых сооружениях реализуется система мониторинга. В случае если система мониторинга выводит отклоненные от нормы значения (например, выше определенного порога), рассматривается возможность закрытия участка дороги, пролегающей по мосту. Аномальные значения могут возникать по двум причинам: по причине действительного предельного состояния конструкций сооружения или по причине неисправности отдельного компонента системы мониторинга, в частности датчика.

Чтобы избежать потенциального перекрытия участка железной дороги по причине отказа датчика можно следовать разным подходам.

Одним из возможных методов является обнаружение отказов датчиков в реальном времени [2]. Недостатком данного подхода является существование объекта в течение некоторого времени без наблюдения, что ведет к потере данных для анализа его состояния.

Еще одним решением может служить прогнозирование будущих отказов датчика, что на данный момент не реализовано в отечественной практике. Это позволит заблаговременно произвести диагностику и при необходимости замену неисправного датчика. Также данный тип методов может служить для того, чтобы отличать отказ датчика от неисправностей прочих составляющих системы, таких как аналогово-цифровой преобразователь. Последнему подходу и посвящена данная работа.

В данной работе будут рассматриваться отказы тензометрических датчиков. Данный тип датчиков широко используется для мониторинга механического напряжения отдельных частей конструкции сооружения. На основании возвращаемой ими величины можно судить о состоянии наблюдаемого моста. Соответственно прогнозирование будущих отказов тензометрических датчиков является актуальной задачей.

Прогнозирование отказа датчика сводится к задаче прогнозирования временного ряда. Специфика названной ранее задачи заключается в том, что рассматриваемый тип отказов тензодатчиков проявляется в аномальном представлении временного ряда возвращаемых измерений: наблюдается смещение среднего значения ряда, что накладывает ограничение на используемые методы решения. В дополнение к этому при прогнозировании необходимо учитывать пагубное влияние некоторых факторов. Рассматривая датчик в составе системы мониторинга железнодорожного моста, такими факторами могут являться температура, задаваемая погодными условиями, и циклические нагрузки на датчик, создаваемые стуком колес вагонов поезда.

Целью данной работы является исследование возможности прогнозирования отказов тензометрических датчиков, учитывая негативное влияние температуры и циклических нагрузок.

Методы машинного обучения способны выявлять сложные зависимости, что относится к рассматриваемому в настоящей работе случаю. Необходимо принимать во внимание то, что на отказы датчика влияет несколько факторов, совокупное воздействие которых тяжело рассчитывается. Также необходимо учитывать, что параметры разных серий датчиков могут отличаться. Машинное обучение позволяет упростить процесс анализа состояния датчика, что упрощает реализацию прогнозирования отказов. Подобные задачи могут решаться с помощью построения модели классификатора [3]. При этом данные делятся на два класса: соответствующие будущей поломке и не соответствующие будущей поломке.

Из-за редкости как такового явления отказа датчика, данных из реальных систем недостаточно, чтобы построить модель классификатора. В следствие этого в ходе работы была построена модель на основании синтетического набора данных.

1 Причины отказов тензометрических датчиков

Тензометрический датчик предназначен для измерения деформации поверхности исследуемого объекта. Зная величину деформации можно судить о механическом напряжении объекта, например, такого как опора моста.

Самым распространенным типом тензодатчиков является тензорезистивные датчики. При нагружении объекта возникает деформация его поверхности, что изменяет электрические параметры чувствительного элемента датчика. В рассматриваемом типе тензодатчиков чувствительным элементом является тензорезистор. Существует много разновидностей тензорезисторов. На рисунке 1 изображается тензорезистор с простейшей геометрией.




Рисунок 1 – Простейший тензорезистор

В основном тензорезисторы изготавливаются из тонкой металлической фольги, которая приклеивается на гибкую подложку, что позволяет тензорезистору деформироваться и изменять свое сопротивление. На диэлектрическую подложку (например, полимерную плёнку или слюду) в вакууме через маску напыляют плёнку металлического сплава, либо формируют проводящую конфигурацию на подложке фотолитографическими методами, однако существуют и другие технологии [4].

При растяжении тензорезистора, изображенного на рисунке 1, его сопротивление будет возрастать, так как происходит значительное удлинение и уменьшение поперечного сечения проводника элемента. Соответственно при сжатии сопротивление будет убывать. Для включения тензорезистора в

электрическую цепь предусмотрены контактные площадки. Принцип действия тензорезистора изображен на рисунке 2.




Рисунок 2 – Принцип работы тензорезистора

1.1 Неисправности тензометрических датчиков

К основным неисправностям в процесс эксплуатации тензорезисторных схем можно отнести:

- 1) смещение нуля,
- 2) снижение чувствительности,
- 3) нарушение целостности моста.

Смещение нуля, также известное как остаточная погрешность нулевой точки, проявляется как постепенное изменение среднего значения ряда измерений датчика. В процессе диагностики данная неисправность выявляется путем сравнения напряжения датчика в разгруженном состоянии со значением напряжения, указанного в технической документации к данному датчику.

Чувствительность тензодатчика характеризуется интенсивностью изменения относительного сопротивления проводника в зависимости от воздействующей относительной деформации. Обычно снижение чувствительности сопровождается смещением нуля. В ряде измерений снижение тензочувствительности можно определить по убыванию дисперсии ряда.

Нарушение целостности моста проверяется путем измерения входного и выходного сопротивления. Изменения мостового сопротивления чаще всего вызвано отказом тензорезистора. Данная неисправность может совпадать с рядом измерений деформации детали во времени, представленном на рисунке 3.

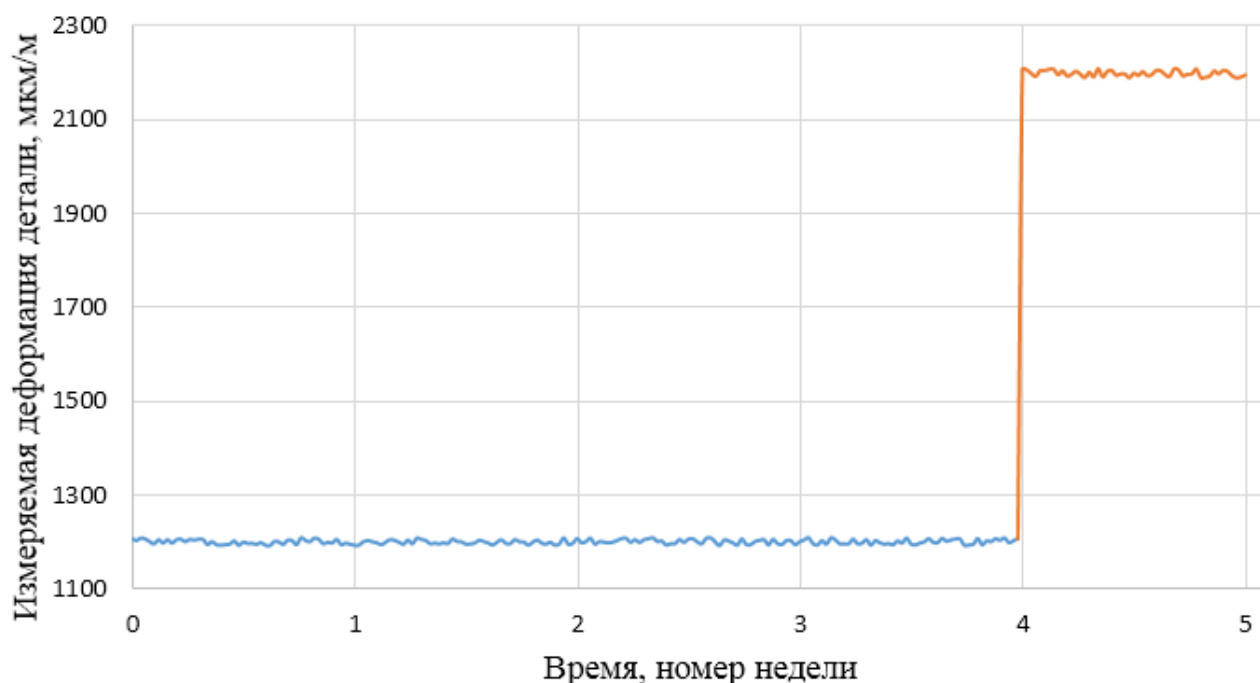


Рисунок 3 – Временной ряд измерений тензодатчика с отказом

Как видно из рисунка 3 нарушение целостности моста тензодатчика проявляется в виде значительного отклонения значений от среднего по ряду. Данная неисправность считается достаточно серьезной для замены датчика, так как в этом случае данные начинают значительно искажаться, что проявляется как в смещении среднего по ряду, так и в изменении дисперсии под влиянием температуры. Поэтому далее будут рассматриваться причины возникновения именно этого типа неисправностей.

1.2 Нарушение целостности моста

Сложность измерений с использованием тензорезисторов определяется малым диапазоном изменения его сопротивления под воздействием деформации. Для 100 Ом датчика они составляют около 0,0002 Ом на деформацию 1 мкм/м. Таким образом, деформация 1000 мкм/м (соответствующая приращению напряжения стали примерно 200 МПа) изменяет сопротивление 100 Ом датчика на 0,2 Ом. Для преобразования столь малых изменений сопротивления в выходные сигналы напряжения, которые могут регистрироваться, в измерительных приборах широко используется мостовая схема Уитстона. В зависимости от количества тензорезисторов, включаемых в измерительный мост, возможны три модификации мостовой схемы: четверть моста, полумост и полный мост, что иллюстрирует рисунок 4 [5].




Рисунок 4 – Модификации мостовой схемы с тензорезисторами

Изменение сопротивления тензорезистора в эксперименте, как правило, зависит от двух факторов: уровня измеряемой деформации и величины изменения температуры в месте установки датчика.

Для уменьшения влияния температуры могут использоваться тензорезисторы на основании сплавов с низким температурным коэффициентом удельного сопротивления. Такие датчики называют температурно-компенсированными датчиками. Температурно-компенсированные датчики для каждого конкретного конструкционного материала подбирают по так называемому S-T-C коду (self-temperature compensation code), который численно

равен коэффициенту теплового расширения конструкционного материала, увеличенному в миллион раз. Типичными сплавами, используемыми в тензорезисторах, являются константан и карма.

Также для температурной компенсации можно воспользоваться разнообразием модификаций мостовой схемы Уитстона. Если рассматривать полумост рисунка 5, то температурная компенсация обеспечивается тем, при деформации детали тензорезисторы изменяют своё сопротивление с обратным знаком. Это достигается наклеивкой тензорезисторов на поверхности по-разному деформируемых зон детали, например, с разных сторон изгибаемой балки или с одной стороны, но со взаимно перпендикулярной ориентацией. При изменении температуры, если температура обоих резисторов равна, знак и величина изменения сопротивления (вызванного изменением температуры) равны, и температурный уход при этом компенсируется. Соответственно при выходе из строя одного из тензорезисторов, как в случае нарушения целостности моста, температурная компенсация нарушается, что изменяется дисперсию ряда.

Смещение значений ряда после события рассматриваемой неисправности объясняется тем, что в месте неисправного тензорезистора происходит разрыв цепи, и ток проходящий через вольтметр увеличится, соответственно показания вольтметра тоже мгновенно сместятся. В какую сторону произойдет смещение показаний вольтметра, в отрицательную или положительную, зависит от того какой резистор выйдет из строя. Нарушение целостности моста по причине выхода из строя одного из резисторов представлено на рисунке 5.




Рисунок 5 – Выход из строя одного из резисторов измерительного моста

В качестве причин разрушения тензорезистора могут выступать броски напряжения (например, молния), ударная нагрузка, воздействие высокой температуры, усталость металла. Усталость металла возникает вследствие циклических нагрузок, что является популярной проблемой [6].

При действии циклических деформаций в конструктивных элементах тензорезистора (чувствительном элементе, связующем, выводных проводниках) могут возникать усталостные трещины. Усталостные процессы приводят к появлению в сигнале тензорезистора смещения нуля, вызывают изменение чувствительности датчика к деформациям, а по мере развития трещины — к разрушению тензорезистора. Причем оба эти явления начинают проявляться практически одновременно. Заметное искажение сигнала датчика наблюдается после некоторого числа циклов, зависящего от уровня деформации. Так, константановые датчики марки 2ФКПА-3-100ГВ, наклеенные лаком ВЛ-931, имеют ресурс 1000 циклов при деформации $\varepsilon = \pm 3000$ мкм/м, а при деформации $\varepsilon = \pm 2000$ мкм/м ресурс увеличивается до 100 000 циклов [5].

Известно, что сопротивление усталостному разрушению металлических материалов зависит не только от амплитуды нагружения, но и от природы материала и температурных условий. Данные по температурной зависимости кинетики параметров усталостного разрушения материалов ограничены и

противоречивы. Для разных марок стали повышение температуры циклического нагружения в большинстве случаев ускоряет процесс роста усталостных трещин [7]. Но для таких сплавов как константан и карма, из которых изготавливаются тензорезисторы, понижение температуры приводит к ускорению, а при высоких — к замедлению разрушения. Соответственно число циклов до разрушения тензорезисторов будет тем меньше, чем ниже температура.

1.3 Выводы по разделу

В данном разделе были описаны общие типы неисправностей тензометрических датчиков. Отказом тензодатчика, критической неисправностью датчика, после события которой датчик не может нормально функционировать, считается нарушение целостности моста (в случае использования датчиков на основе мостовых схем) или неисправность отдельного электронного компонента, а именно тензорезистора.

Нарушение целостности моста тензорезистора часто происходит в следствие выхода из строя тензорезистора, в составе одного из плеч моста, вследствие пагубного воздействия циклических нагрузок. Тензорезисторы подвержены так называемому усталостному разрушению, которое происходит вследствие развития усталостных трещин в металлическом материале. Усталостная долговечность зависит от природы материала и условий испытания, амплитуды нагружения и температуры. Зависимость скорости развития трещины от величины прикладываемой нагрузки очевидна, чем выше нагрузка, тем скорее наступает разрушение. Однако зависимость от значения температуры не однозначно для разных материалов. Для наиболее популярных сплавов, из которых изготавливаются тензорезисторы, константана и карма, характерно уменьшение числа циклов нагружения с убыванием температуры относительно комнатной.

На основании выше сказанного выводится, что для успешного прогнозирования такого явления, как отказ тензометрического датчика, помимо

данных об измеряемой датчиком нагрузке, а именно среднем уровне измеряемой деформации и количестве циклов нагружения, необходимо учитывать еще и температуру, непосредственно влияющую на усталостную долговечность тензорезисторов.

2 Обзор подходов к прогнозированию

Как ранее отмечалось прогнозирование отказа датчика сводится к задаче прогнозирования временного ряда. Учитывая быстрое во времени изменение ряда и воздействие внешних условий на состояние датчика, необходимо определить произойдет ли в заданный будущий интервал времени отказ датчика. Похожие задачи решаются с помощью методов прогнозирования численного признака временного ряда либо классификации данных.

2.1 Обзор методов прогнозирования численного признака временного ряда

Прогнозирование используется во многих сферах жизни, вследствие чего существует немало моделей, решающих данную задачу. В существующей литературе можно найти такие модели, как экспоненциальное сглаживание (ES) [8], модель TBATS [9] и интегрированная модель авторегрессии — скользящего среднего (ARIMA) [10].

2.1.1 Интегрированная модель авторегрессии - скользящего среднего

Интегрированная модель авторегрессии - скользящего среднего, ARIMA (Autoregressive Integrated Moving Average), была сформирована на основании хорошо известного метода исследования данных временных рядов ARMA [11], совместившего в себе две более простые модели авторегрессии (AR) и скользящего среднего (MA). Рассматриваемая модель используется для прогнозирования данных линейных временных рядов путем преобразования нестационарных данных в стационарные [12].

Примерами использования моделей на основе ARIMA могут служить прогнозирование погодных условий [13], фондового рынка [11] и электрических нагрузок [14]. Кроме того, модели ARIMA использовались при обнаружении аномалий для конкретных применений в таких промышленных секторах, как нефтепереработка [15] и сетевая безопасность [16].

2.1.2 Экспоненциальной сглаживание

Экспоненциальное сглаживание, ES (Exponential smoothing), сглаживает временные ряды с помощью экспоненциальной оконной функции. Уравнения ES позволяют методу эффективно фиксировать основные компоненты отдельных рядов, такие как сезонность и уровень, основываясь на предварительных предположениях. ES использует экспоненциальные функции для назначения экспоненциально убывающих весов с течением времени, в то время как в обычном методе скользящей средней прошлые наблюдения взвешиваются одинаково.

Экспоненциальное сглаживание является базой для многих других моделей, таких как TBATS и прочих комбинированных моделей [17], увеличивающих те или иные показатели качества прогнозирования. Также рассматриваемая модель может использоваться для прогнозирования электропотребления [18], транспортных потоков [19] или качества воздуха [20].

2.1.3 Модель TBATS

Модель TBATS — это метод экспоненциального сглаживания, который включает преобразование Бокса-Кокса (метод нелинейных данных), модель ARMA для невязок и тригонометрическую сезонность. Тригонометрическое выражение сезонности может значительно уменьшить параметры модели при высоких частотах сезонности и в то же время предложить пластичность модели для компромисса со сложной сезонностью. С отрицательной стороны, вычислительные затраты значительно велики, если файлы данных огромны, однако среди сильных сторон этой модели есть: возможность реализации многосезонного анализа без слишком большого количества параметров; она может работать при нецелой сезонности; она может работать при высокочастотных данных [21].

2.2 Обзор методов классификации

Прогнозировать будущий отказ датчика можно с помощью разбиения данных на два класса: класс, соответствующий будущему отказу, и класс, соответствующий будущей исправности. Из основных моделей можно выделить k-ближайших соседей, случайный лес, метод опорных векторов.

2.2.1 Метод k-ближайших соседей

Метод k-ближайших соседей, kNN (k-Nearest Neighbours), основывается на простейшем методе классификации, методе ближайшего соседа. Для повышения надёжности классификации объект относится к тому классу, которому принадлежит большинство из его соседей ближайших к нему объектов обучающей выборки. Данный метод опираются на одно важное предположение, называемое гипотезой компактности: если мера сходства объектов введена достаточно удачно, то схожие объекты гораздо чаще лежат в одном классе, чем в разных. В этом случае граница между классами имеет достаточно простую форму, а классы образуют компактно локализованные области в пространстве объектов [22].

2.2.2 Случайный лес

В его основе лежит дерево решений. Алгоритм дерева решений позволяет определить, какие признаки являются более значимыми. Данные признаки помещаются на верх дерева, постепенно переходя затем к менее значимым признакам.

К сожалению, верхние уровни дерева решений сильно влияют на ответ, и, если новые данные не следуют тому же распределению, что и обучающая выборка, может пострадать способность модели к обобщениям. Именно здесь на помощь приходит модель на базе алгоритма случайный лес. Построение набора деревьев снижает этот риск. При поиске ответа в случае классификации выбирается большинство голосов, а в случае регрессии —

среднее. Благодаря использованию голосов или средних появляется возможность получить полные вероятности, которую дают не все алгоритмы.

Случайные леса имеют и ряд других преимуществ, например, нечувствительность к несущественным признакам, зашумленным наборам данных с пропущенными значениями и неверно помеченным записям, хотя имеют склонность к переобучению [23].

2.2.3 Метод опорных векторов

Алгоритм, называемый методом опорных векторов, SVM (Support Vector Machine), часто выбирают для решения как линейных, так и нелинейных задач. Он обладает рядом интересных теоретических и практических свойств, которые делают его полезным во многих сценариях. Основная идея алгоритма, состоит в поиске линии (или гиперплоскости в случае большего числа измерений), разделяющей два класса. Но алгоритм не измеряет расстояние до всех точек, а пытается найти максимальный зазор исключительно между точками по обе стороны от линии решений. Основная идея такого подхода состоит в том, чтобы избавиться от необходимости учитывать точки, корректно расположенных внутри границ, интерес вызывают только близкие к границам точки [24].

Самой простой ядерной функции метода опорных векторов является линейная функция. Названное ядро применяется для быстрого решения задачи классификации и в случае линейно разделимого набора данных. Для более сложных выборок в большинстве случаев используется ядро радиально базисной функции [25].

2.3 Выводы по разделу

В данном разделе были разобраны два типа моделей: модели прогнозирования численного признака временного ряда и модели классификации.

Общим недостатком для моделей предсказания численного признака временного ряда проблема работы с несколькими временными признаками.

Даже если расширить набор данных до двух временных рядов, соответствующих двум разным признакам, задача уже значительно усложняется.

Помимо этого, существует проблема редкости возникновения явления отказа датчика. Модели рассматриваемого типа тем слабее учитывают данные, чем дальше они находятся от конца временного ряда. Данная сложность устранима при условии постоянного периода времени между соседними отказами датчиков, но, как правило, длительность работы датчика — непостоянна.

Отдельным недостатком для сглаживающих моделей, таких как экспоненциальное сглаживание, является невозможность уловить мгновенное во времени изменение ряда, как в случае с нарушением целостности моста тензодатчика. Вместе с достоинством данных методов в подавлении шумов, возникает недостаток в рамках задачи данной работы.

Модели классификации позволяют минимизировать или даже избавиться от названных сложностей. В данном разделе были рассмотрены наиболее популярные модели классификации.

Для достижения цели данной работы была выбрана модель опорных векторов с радиально базисной ядерной функцией, лишенная недостатка хранения всех обучающих объектов, как в случае с методом k -ближайших соседей, и наличие меньшего риска переобучения по сравнению с моделью случайного леса.

3 Математическое описание метода классификации

В текущем разделе приводится математическое описание выбранного метода классификации, а именно метода опорных векторов с радиально базисной ядерной функцией.

3.1 Метод опорных векторов

Метод опорных векторов описывает гиперплоскость или набор гиперплоскостей в пространстве большой или бесконечной размерности. Хорошее разделение достигается за счет гиперплоскости, которая имеет наибольшее расстояние до ближайших точек обучающих данных любого класса (так называемый функциональный запас), поскольку, как правило, чем больше запас, тем ниже ошибка обобщения классификатора. На рисунке 6 показана функция решения для линейно разделяемой задачи с тремя образцами на границах запаса, называемыми «опорными векторами».




Рисунок 6 – Функция решения для линейно разделяемой задачи

Когда проблема не является линейно разделяемой, опорные векторы являются выборками в пределах границ поля.

Для построения модели SVM используется обучающий набор данных, то есть набор данных, содержащий пары данных $\{X_{i,m}, Y_i\}$, в которых переменные $X_{i,m}$ сопоставляются с выходным значением отклика Y_i . Основная цель SVM логики создать функцию $Y = f(X_m)$, которая наилучшим образом отражает соотношение ввода-вывода из обучающего набора данных. Все нелинейности моделируемой системы обрабатываются включением так называемых функций ядра. Обучающий набор данных используется для разработки опорных векторов, которые играют решающую роль, поскольку они отвечают за производительность модели и ее способность к обобщению. Поэтому выбор обучающего набора данных может сильно влиять на результаты и является ключевым шагом при использовании SVM. Здесь же кроется и самая большая слабость логики SVM — для того чтобы уловить взаимосвязь "вход–выход" и правильно обучить модель, набор данных должен быть достаточно большим, и он должен быть подготовлен заранее.

После обучения модель может быть использована для оценки других случаев. Обычно производительность модели тестируется с использованием так называемого тестового набора данных.

Моделирование SVM типа 1 состоит из выбора подходящей функции ядра и параметров. В радиальной базисной функции число опорных векторов косвенно связано с C и γ параметры. Параметр C обозначает вес параметра емкости. Этот параметр определяет компромисс между сложностью и допуском на ошибку в прогнозировании этой функции. Параметр γ является свободным параметром гауссовой радиальной базисной функции. Было замечено, что косвенное управление опорными векторами с помощью параметров модели C и γ , часто приводит к созданию слишком большого количества опорных векторов в модели SVM и переобученности модели. Использование половины общего числа данных в обучающем наборе в качестве опорных векторов было оптимальным для большинства задач. Чтобы обеспечить непосредственное задание числа опорных векторов в разработанной модели, были разработаны

другие типы SVM-моделей, известные как ν -SVM или SVM типа 2, которые нуждаются в двух параметрах, C и ν , для задания модели. Параметр ν , который находится в диапазоне от 0 до 1, контролирует число опорных векторов и является нижней границей доли опорных векторов, используемых в разработанной модели. Этот параметр является мерой компромисса между точностью модели для обучающих данных и сложностью модели (количеством опорных векторов).

3.2 Выводы по разделу

В данном разделе было разобрано математическое описание метода опорных векторов. Рассмотрены несколько типов методов и их гиперпараметры. Также описан выбор числа опорных векторов в случае радиально базисной функции.

4 Прогнозирование отказов тензометрических датчиков

На основании проведенного обзора подходов к прогнозированию для прогнозирования отказов тензометрических датчиков будет использоваться модель опорных векторов. Так как на текущий момент необходимое количество данных для обучения классификатора, включающих отказы датчиков в реальных системах, недостаточно, в этой работе будет рассматриваться синтетический набор данных.

4.1 Создание набора данных

Как было описано в разделе 1, время работы датчика при циклических нагрузках зависит от количества циклов нагружения, амплитуды нагружения и температурных условий.

4.1.1 Стук колес

Циклическая нагрузка задается ударами колес вагонов поезд по рельсам во время пересечения моста. Стук происходит в момент перехода колеса вагона с одного рельса на следующий, при этом первый рельс прогибается под тяжестью вагона. В итоге колесо оказывается в положении ниже высоты следующего рельса, что в процессе движения вызывает стук.

Ритмичность стука объясняется тем, что место стыка рельс пересекает две ближайших друг к другу пары колес соседних вагонов.

Явление стука колес о рельсы и сам поезд создает нагрузку на мостовое сооружение, что можно увидеть в процессе измерения деформаций конструкций моста (опор, пролетов), при достаточной дискретизации данных. При этом ряд измерений деформаций будет подобен изображенному на рисунке 7 [26].




Рисунок 7 – Деформации при стуке колес

Каждый отдельный локальный максимум считается одним циклом нагружения. Также необходимо заметить, что амплитуда возникающей нагрузки будет зависеть от силы удара колеса о рельс, которая в свою очередь зависит от величины зазора стыка рельс. Величина зазора зависит от длины моста, климатической зоны, температуры и прочих обстоятельств в конкретный момент времени.

Путевые рельсы на мостах длиной более 300 м укладываются типа Р65 длиной 25 м, на остальных мостах длиной 12,5 м [27]. Для генерации данных выберем длину моста более 300 м и климатическую зону с годовой амплитудой колебания температуры рельсов от 80 °С до 100 °С. Так для температуры 30 °С зазор будет составлять 3,0 мм и для температуры минус 20 °С — 19,5 мм [28]. Величина зазора изменяется более чем в 6 раз. Считая, что величина деформации конструкции зависит линейно от величины зазора, амплитуда деформации при ударе будет изменяться от 100 до 600 мкм/м (для вагонов массой 65 тонн, радиусом колеса 0,35 м и скорости движения поезда 90 км/ч), в зависимости от сезона. То есть в холодное время года нагрузка, испытываемая конструкцией моста, будет сильнее, чем летом. В подобных условиях вероятность слома проводящего металлического материала тензорезистора и соответственно отказа самого тензодатчика выше в холодное время года.

Как видно на рисунке 7 локальные максимумы от стука двух соседних пар колес могут наблюдаться менее чем за секунду. Чтобы хранить данные с достаточно большой дискретизацией за несколько лет необходимы огромные объемы памяти. В зависимости от используемой системы в целях хранения данные усредняют по интервалам от 20 с до 20 мин. Принимая во внимание это, для учета количества циклов нагружения можно использовать расписание нагрузок подобное расписанию движения поездов (время пересечения локомотивом моста, количество вагонов).

4.1.2 Усталостная прочность

Как упоминалось ранее усталостная прочность зависит от количества циклов нагружения и амплитуды нагружения. Количество циклов нагружения при определенном уровне амплитуды зависит от габаритов компонента, испытываемого сплава и даже от применяемой подложки и клея. То есть для отдельных серий тензорезисторов своя усталостная прочность.

При изображении кривой усталостной прочности тензорезисторов по оси абсцисс откладывается количество циклов нагружения в логарифмическом масштабе, а по оси ординат — модуль уровня циклической деформации. Рассматривая общий случай, типичная усталостная прочность тензорезисторов серии общего назначения представлена на рисунке 8.




Рисунок 8 – Усталостная прочность тензорезисторов общего назначения

Так для деформации тензорезистора значением 1200 мкм/м ресурс усталостной прочности составляет около $6 \cdot 10^6$ циклов. Необходимо заметить, что деформации, испытываемые тензорезистором, также могут иметь годовую сезонность. Это происходит из-за недостаточной температурной компенсации системы «датчик-деталь». В зависимости от периода сезона тензорезистор будет сжиматься или растягиваться по причине температурного расширения наблюдаемой детали. Сезонная амплитуда изменения деформации тензорезистора в разных условиях может превышать 150 мкм/м. Представление деформаций тензорезистора может выглядеть в соответствии с рисунком 9.




Рисунок 9 – Сезонность деформаций тензорезистора

4.1.3 Учет температуры

Принимая во внимание то, что амплитуда нагрузки на конструкцию при ударе колес по рельсам и среднее значение деформации самого тензорезистора зависят от температуры, делается вывод о том, что для прогнозирования отказов тензорезисторов при изменчивых условиях окружающей среды, необходимо учитывать температуру, которой обладает тензорезистор. Как известно, величина охлаждения или нагрева объекта под действием окружающей среды, а именно погодных условий, зависит от температуры сухого воздуха, влажности воздуха и скорости ветра. Воздействие ветра минимизируется как на приборы измерения температуры, так и на тензодатчики. Для анализа измеряемых деформаций тензорезистором это позволяет учитывать исключительно температуру, рассчитываемую на метеостанции или с помощью отдельных датчиков, без дополнительного учета данных о ветре и влажности окружающего воздуха.

4.1.4 Получение данных

Основываясь на сказанном, необходимо создать данные о периодах циклического нагружения датчика, временной ряд температуры воздуха, данные об измеряемых нагрузках.

4.1.4.1 Данные об изменении количества циклов нагружения со временем

В качестве упрощения можно считать, что расписание движения поездов по мосту — постоянен: каждые три часа с 10-00 до 22-00 мост пересекают шесть

поездов и каждые три часа с 22-00 до 10-00 следующего дня — три поезда. Таким образом количество поездов, пересекающих мост за сутки, будет выглядеть в соответствии с таблицей 1.

Таблица 1 – Количество поездов в сутки

Время	1:00	4:00	7:00	10:00	13:00	16:00	19:00	22:00
Количество проехавших локомотивов за прошедшие 3 часа	3	3	3	3	6	6	6	6

Период времени в три часа был выбран для удобства сопоставления с рядом температуры.

Грузовой локомотив в состоянии перевезти от станции одного населенного пункта до станции другого населенного пункта до 75 полных вагонов, а для пассажирского предусмотрено от 16 до 20 вагонов. Также на каждом вагоне по четыре пары колес.

Создадим данные о количестве циклов нагружения между соседними отсчетами времени, соответствующий количеству ударов на стыке рельс за каждые полчаса в соответствии с расписанием таблицы 1. Для каждой новых суток данный признак будет содержать значения в соответствии с таблицей 2.

Таблица 2 – Количества циклов нагружения между соседними отсчетами времени для каждой новых суток

Время	1:00	4:00	7:00	10:00	13:00	16:00	19:00	22:00
Количество циклов нагружения за прошедшие 3 часа	438	430	458	422	844	872	900	836

4.1.4.2 Данные о температуре

Целесообразно использовать реальные данные о температуре в рамках текущего исследования. Можно обратиться к архивам погоды [29]. Истории погоды одного города будет недостаточно, так как необходим довольно большой объем данных, поэтому соберем историю из разных городов одного климата. Используем архивы погоды умеренного пояса, области умеренно континентального климата, двенадцати городов, а именно:

- Архангельск,
- Воронеж,
- Екатеринбург,
- Казань,
- Киров,
- Москва,
- Нижний Новгород,
- Пермь,
- Псков,
- Самара,
- Сыктывкар,
- Ярославль.

Изменения температуры воздуха в Казани в период с 2005 по 2021 год изображены на рисунке 10.




Рисунок 10 – Температура воздуха в Казани

4.1.4.3 Данные об отказе датчика

Для определения момента отказа датчика необходимо учесть:

- амплитуду нагрузки (средняя нагрузка),
- сезонность деформаций тензорезистора (отклонение от среднего в течение сезона),
- природу циклической нагрузки (зависимость амплитуды циклического нагружения от температуры и прочих факторов),
- количество циклов нагружения,
- влияние температуры на усталостную долговечность тензорезисторов.

Целесообразно задать разные амплитуды нагружения и разные сезонные отклонения, чтобы расширить работу классификатора на случаи с разными нагрузками и системами «датчик-деталь», но все еще одинаковым типом тензодатчиков. Чтобы учесть разные типы датчиков необходимо сгенерировать

данные об отказах для разных характеристик усталостной прочности, что не будет рассматриваться в данной работе.

Реализуем усталостное разрушение по порогу. Когда оставшийся усталостный ресурс достигнет порога, будет зафиксирован отказ датчика. Параметрами, влияющими на усталость тензорезистора, также являются вес вагона, диаметр колес, скорость движения поезда, тип и состояние уложенных рельс и прочие факторы. Чтобы учесть подобные переменные, влияющие на усталость датчика, зададим порог оставшегося ресурса в соответствии с нормальным распределением при среднеквадратическом отклонении, равным $158,5 \cdot 10^3$, и математическом ожидании равным нулю. Тогда плотность вероятности порога оставшегося ресурса будет соответствовать рисунку 11.




Рисунок 11 – Распределение плотности вероятности порога оставшегося ресурса тензорезистора датчика

Сам оставшийся ресурс тензорезистора будет рассчитываться по рекуррентной формуле:

$$r_{i+1} = r_i - \alpha_d \alpha_t \alpha_h \cdot 1, \quad (1)$$

где i – инкрементируемая переменная, совпадающая с количеством циклов нагружения датчика, $i = 0, 1, 2, \dots$,

r – оставшийся ресурс тензорезистора датчика, при r_0 принадлежащему множеству значений функции усталостной прочности в соответствии с рисунком 8, количество циклов нагружения,

α_d – весовой коэффициент сезонного отклонения значений деформаций, испытываемых тензорезистором,

α_t – весовой коэффициент скорости развития усталостных трещин в зависимости от температуры,

α_h – весовой коэффициент амплитуды циклической нагрузки.

Единица в формуле (1) отражает процесс расходования ресурса тензорезистора. При одном цикле нагружения от оставшегося ресурса отнимается взвешенная единица.

Весовой коэффициент α_d зависит от сезонного отклонения от среднего значения деформации. А закон изменения данного коэффициента зависит от среднего по ряду. Функция весового коэффициента α_d для средней измеряемой деформации 1200 мкм/м будет соответствовать закону на рисунке 12.



Рисунок 12 – Коэффициент сезонного отклонения деформации

Весовой коэффициент α_t будет изменяться линейно относительно температуры в соответствии с графиком рисунка 13.




Рисунок 13 – Весовой коэффициент скорости развития усталостных трещин в зависимости от температуры

Весовой коэффициент α_h отражает влияние амплитуды колебаний деформаций при циклической температуре в зависимости от температуры. Основываясь на том, что амплитуда циклического нагружения зависит от температуры линейно, задаем линейную зависимость коэффициента α_h от температуры в соответствии с рисунком 14.




Рисунок 14 – Коэффициент амплитуды циклической нагрузки в зависимости от температуры

Необходимо заметить, что коэффициенты α_t и α_h равны единице при 20 °C, что соответствует расходу одного цикла нагружения от оставшегося

ресурса тензорезистора в соответствии с характеристикой усталостной прочности.

Для генерации ряда деформаций, измеряемых тензодатчиком, необходимо задать среднее значение ряда, характер изменения отклонения от среднего, максимальное отклонение от среднего. В рамках данной работы среднее значение будет выбираться случайным образом на отрезке от 1075 до 1325 мкм/м; характер изменения отклонения от среднего будет задаваться линейным законом; максимальное значение отклонения от среднего будет выбираться случайным образом на отрезке от 10 до 80 мкм/м. В соответствии с заданными условиями генерации гистограмма количества отказов на промежутках длительностью 40 суток будет соответствовать рисунку 15.



Рисунок 15 – Гистограмма количества отказов на промежутках длительностью 40 суток

Общее количество рядов измерений датчиков составило 33, а наиболее вероятное время работы датчика — 3 года и 1 месяц.

4.2 Подготовка данных

Перед передачей данных классификатору необходимо извлечь признаки, провести разметку и прочее.

4.2.1 Извлечение признаков

На основании информации об количестве циклов нагружения между соседними отсчетами времени и значениях температуры воздуха можно сформировать гистограмму количества циклов нагружения по температурным полуинтервалам. В такой форме данные можно подавать на вход классификатора. Данный признак будет отражать зависимость усталостного ресурса как от температуры, так и от количества циклов нагружения. Для одного из сгенерированных рядов отказа датчика на основании температурного ряда Казани была получена гистограмма, изображенная на рисунке 16.



Рисунок 16 – Гистограмма количества циклов нагружения по температурным полуинтервалам

При генерации некоторого ряда измерений датчика, связанного с температурным рядом Казани, была задана линейная функция (2) отклонения от среднего значения деформации с начальным отсчетом времени при 0 °C.

$$d = -\frac{1}{40}d_{max}t, \quad (2)$$

где d – отклонение от среднего по ряду, мкм/м,

d_{max} – отклонение от среднего при 40 °C, мкм/м,

t – температура, °C.

При генерации данных измерений деформаций на ряд накладывается равномерный шум. Поэтому средние значения отклонений от среднего по ряду

относительно целых значений температуры будут выглядеть в соответствии с рисунком 17.

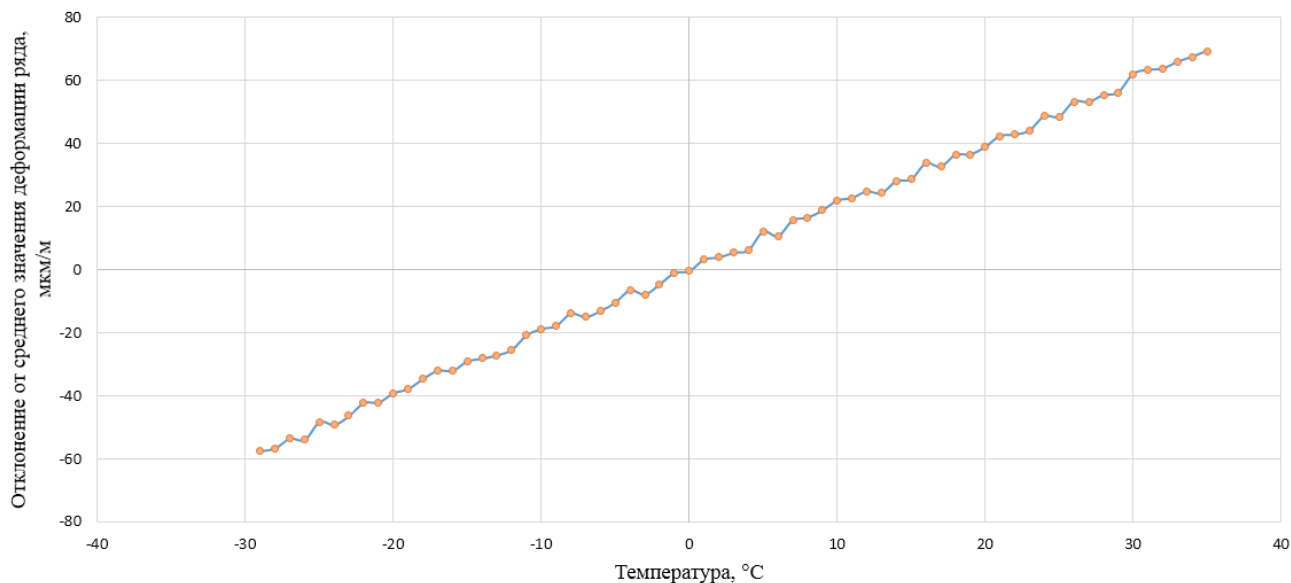


Рисунок 17 – Средние значения отклонений от среднего по ряду относительно температуры

В таком виде данные можно подавать на вход классификатора. Причем если деформация для какой-то температуры отсутствует, то данной температуре сопоставляется ноль, и если какая-то деформация соответствует температуре принадлежащей одному из лучей $t \leq -33$ или $t > 38$, то значения деформаций всего луча принадлежат одной области усреднения.

Также на вход классификатора подается среднее значения ряда деформаций.

Итого на вход классификатора будет подаваться 145 признаков.

4.2.2 Разметка данных

Данные будут делиться на два класса:

- а) данные, соответствующие будущему отказу,
- б) данные, соответствующие бедующей исправности.

Класс пункта а) будем считать основным и положительным. Соответственно класс пункта б) будем считать отрицательным.

Для разметки данных необходимо выбрать интервал прогнозирования. В данной работе будет рассматриваться интервал длиной в одну неделю. Этого времени будет достаточно, чтобы своевременно провести диагностику и возможно замену неисправного датчика.

Соответственно все объекты за неделю до отказа будут принадлежать положительному классу, а прочие (исключая сам отказ) — отрицательному классу. Это иллюстрирует рисунок 18, где объекты третьей недели принадлежат положительному классу, а объекты до третьей недели — отрицательному.




Рисунок 18 – Разметка на примере ряда измеряемых деформаций

4.2.1 Балансировка данных

Если создать максимальное количество объектов данных, каждый из которых будет соответствовать промежутку времени от начала функционирования датчика и до каждого следующего трехчасового отсчета времени, то окажется что данные разбалансированы, то есть количество объектов, соответствующих положительному классу, будет превышать в несколько раз количество объектов, соответствующих отрицательному классу.

В случае несбалансированных данных можно отнести все объекты к наибольшему классу и в этом случае точность будет отражать долю основного класса от общего количества объектов [30]. Такое решение неудовлетворительно.

Для решения обозначенной проблемы будет использоваться метод недостаточной выборки данных (undersampling) [31]. Названный метод подразумевает исключение некоторого количества объектов из избыточного класса для достижения равного количества экземпляров каждого класса.

При заданном интервале прогнозирования необходимо чтобы из каждого ряда отказа датчика было извлечено по 56 экземпляров каждого класса. Соответственно необходимо из всех объектов отрицательного класса выбрать только 56.

Первый выбранный объект будет соответствовать данным после одного года работы датчика. Поломок через один год работы не происходило поэтому этот объект точно будет принадлежать отрицательному классу, как и последующая неделя после него. Вторым объектом будет выбран самый ближайший во времени к объектам положительного класса. Остальные 54 объекта выбираются через равные промежутки времени между первыми двумя.

4.3 Обучение классификатора

Для прогнозирования отказов тензометрических датчиков на основании полученных и подготовленных в работе данных будет использоваться метод опорных векторов с радиальной базисной функцией в качестве ядра.

Модель обучалась на наборе данных разделенным на обучающую выборку, валидационную выборку и тестовую выборку в процентном соотношении 50, 20, 30 % соответственно. Причем после подбора гиперпараметров обучающая и валидационная выборки были объединены и модель переучена.

Как ранее отмечалось при обучении модели метода опорных векторов с ядром радиальной базисной функции необходимо учитывать два параметра: C и γ . Для подбора этих гиперпараметров воспользуемся методом сеточного поиска.

Гиперпараметры будут подбираться по показателю качества модели AUC. Введем сетку для названных гиперпараметров: для C — $[0,1; 1; 10; 100]$, для γ — $[0,001; 0,01; 0,1; 1]$.

Для каждого узла сетки проводится перекрестная проверка и вычисляется выбранная оценочная метрика. В результате для гиперпараметров C и γ были выбраны значения 10 и 0,01 соответственно. ROC-кривая в таком случае будет выглядеть в соответствии с рисунком 19.




Рисунок 19 – ROC-кривая

Выбрав точку (0,21; 0,8) на ROC-кривой, получим значения различных метрик в соответствии с таблицей 3.

Таблица 3 – Значения оценочных метрик

Название оценочной метрики	Значение вычисленной метрики
AUC	0,84
Precision	0,79
Recall	0,8
F-score	0,79

На основании использованных в работе данных классы будущего отказа и будущей исправности оказались хорошо разделимы с помощью ядра радиально базисной функции, исходя из вычисления оценочных метрик. При решении задач бинарной классификации приходится идти на компромисс и выбирать между ошибками в предсказании основного класса и другого класса. При реализации предложенного подхода на основании построенной ROC кривой при выбранных гиперпараметрах можно изменять количество ошибок в предсказании того или иного класса, регулируя порог решающего правила.

4.4 Выводы по разделу

В рамках данного раздела были получены данные для анализа состояния датчика, извлечены признаки для обучения и тестирования качества работы модели и обучена сама модель классификатора.

В процессе получения данных случайным образом было выбрано количество циклов нагружения тензодатчика для каждого следующих трех часов времени. При этом полученные числа оставались постоянными относительно каждого новых суток. Данные о температуре были извлечены из архивов погоды 12 городов с похожим климатом. Также были сгенерированы ряды измерений деформаций датчиком и его отказы. Общее количество рядов измерений датчиков составило 33, а наиболее вероятное время работы датчика — 3 года и 1 месяц.

Из полученных данных были извлечено 145 признаков, подаваемых на вход классификатора. Из них 72 получены из гистограммы количества циклов

нагружения по температурным полуинтервалам, еще 72 — средние значения отклонений от среднего по ряду относительно температуры и еще один это среднее значение ряда измерений.

Гистограмма количества циклов нагружения по температурным полуинтервалам отражает зависимость усталостного ресурса от температуры и количества циклов нагружения. Средние значения отклонений от среднего по ряду относительно температуры передают разность температурных расширений детали и чувствительного элемента датчика.

Данные были поделены на два класса: класс будущего отказа (положительный класс) и класс будущей исправности (отрицательный класс), с интервалом прогнозирования длительностью в одну неделю. Исходя из полученной разметки, возникла необходимость балансировки классов. Набор данных был приведен к сбалансированному с помощью метода недостаточной выборки данных.

Модель обучалась на наборе данных разделенным на обучающую выборку, валидационную выборку и тестовую выборку в процентном соотношении 50, 20, 30 % соответственно. Это позволило провести подбор гиперпараметров для модели метода опорных векторов с радиально базисной функцией в качестве ядра.

Основываясь на вычисленных значениях показателей качества работы классификатора, делается вывод о том, что классы будущего отказа и будущей исправности использованных в работе данных оказались хорошо разделимы с помощью ядра радиально базисной функции.

ЗАКЛЮЧЕНИЕ

В рамках данной работы рассматривалась такая неисправность тензометрического датчика как нарушение целостности моста. Названная неисправность часто возникает вследствие разрушения тензорезистора, являющегося чувствительным элементом рассматриваемого устройства.

В случае воздействия циклических нагрузок происходит усталостное разрушение тензорезистора. Усталостная прочность тензорезистора зависит от количества циклов нагружения, амплитуды нагружения и условий эксплуатации. Значительное влияние на усталостную прочность также имеет температура. При нагружении тензорезистора с переменной температурой задача прогнозирования момента его разрушения усложняется.

На основании поставленной цели были рассмотрены такие типы моделей как модели прогнозирования численного признака временного ряда и модели классификации данных. Принимая во внимание специфику проявления отказа датчика, влияние температуры и прочие условия, в качестве решения был выбран метод опорных векторов с радиально базисной ядерной функцией.

Вследствие недостаточного объема реальных данных был разработан синтетический набор данных об измеряемых деформациях и отказах датчиков. В качестве данных о температуры были использованы архивы погоды двенадцати городов одного климата. В результате было получено 33 ряда данных содержащих в себе данные об измеряемых нагрузках, температуре воздуха и циклах нагружения.

Из полученных данных были извлечено 145 признаков, подаваемых на вход классификатора. Из них 72 получены из гистограммы количества циклов нагружения по температурным полуинтервалам, еще 72 — средние значения отклонений от среднего по ряду относительно температуры и еще один это среднее значение ряда измерений. Проведена разметка данных, а также балансировка методом недостаточной выборки данных.

Модель обучалась на наборе данных разделенным на обучающую выборку, валидационную выборку и тестовую выборку в процентном

соотношении 50, 20, 30 % соответственно. Это позволило провести подбор гиперпараметров для модели метода опорных векторов с радиально базисной функцией в качестве ядра.

Основываясь на вычисленных значениях показателей качества работы классификатора, делается вывод о том, что классы будущего отказа и будущей исправности использованных в работе данных оказались хорошо разделимы с помощью ядра радиально базисной функции.

Рассматриваемый в данной работе подход может использоваться для прогнозирования неисправностей датчиков в составе системы мониторинга мостовых сооружений.

Также полученная модель может быть применена не только к полномостовым тензодатчикам, но и к любым тензорезистивным датчикам под влиянием циклической нагрузки.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Исследование основных проблем в сфере пассажирского транспорта и перевозок / К. Н.Н [и др.] // Транспортное дело России. – 2017. – № 4. – С. 103-105.
2. Sensor Failure Detection and Faulty Data Accommodation Approach for Instrumented Wastewater Infrastructures / K. Thiagarajan [и др.] // IEEE Access. – 2018. – Т. 6. – С. 56562-56574.
3. Predicting stock returns by classifier ensembles : The Impact of Soft Computing for the Progress of Artificial Intelligence / C.-F. Tsai [et al.] // Applied Soft Computing. – 2011. – Vol. 11. – № 2. – P. 2452-2459.
4. Additive manufacturing and characterization of a load cell with embedded strain gauges / G. Stano [et al.] // Precision Engineering. – 2020. – Vol. 62. – P. 113-120.
5. Мехеда В.А. Тензометрический метод измерения деформаций / В.А. Мехеда. – 2011.
6. Makabe M. Research of protection equipment for the load cell receiving a large impact load / M. Makabe, S. Harada // 2006 SICE-ICASE International Joint Conference 2006 SICE-ICASE International Joint Conference. – 2006. – С. 2521-2526.
7. Усталостное разрушение при разных температурах и долговечность штампованных металлоизделий / Г.В. Пачурин [и др.]. – 2010.
8. Hyndman R.J. The admissible parameter space for exponential smoothing models / R.J. Hyndman, M. Akram, B.C. Archibald. – 2008. – С. 407-426.
9. Livera A.M.D. Forecasting Time Series With Complex Seasonal Patterns Using Exponential Smoothing / A.M.D. Livera, R.J. Hyndman, R.D. Snyder // Journal of the American Statistical Association. – 2011. – Т. 106. – № 496. – С. 1513-1527.
10. Whittle P. Hypothesis testing in time series analysis. Т. 4 / P. Whittle. – Uppsala: Almqvist & Wiksells boktr., 1951.

11. Mondal P. Study of Effectiveness of Time Series Modeling (Arima) in Forecasting Stock Prices / P. Mondal, L. Shit, S. Goswami // International Journal of Computer Science, Engineering and Applications. – 2014. – T. 4. – C. 13-29.
12. Kuzin T. Early Failure Detection for Predictive Maintenance of Sensor Parts / T. Kuzin, T. Borovicka // ITAT. – 2016.
13. Geetha A. Time series modeling and forecasting: Tropical cyclone prediction using ARIMA model / A. Geetha, G.M. Nasira // 2016 3rd International Conference on Computing for Sustainable Global Development (INDIACom) 2016 3rd International Conference on Computing for Sustainable Global Development (INDIACom). – 2016. – Time series modeling and forecasting. – C. 3080-3086.
14. Saatwong P. Short-term electricity load forecasting for Building Energy Management System / P. Saatwong, S. Suwankawin // 2016 13th International Conference on Electrical Engineering/Electronics, Computer, Telecommunications and Information Technology (ECTI-CON). – 2016.
15. Anomaly detection and prediction of sensors faults in a refinery using data mining techniques and fuzzy logic / M.R. Saybani [и др.] // Scientific Research and Essays. – 2011. – T. 6. – C. 5685-5695.
16. Moayedi H.Z. Arima model for network traffic prediction and anomaly detection / H.Z. Moayedi, M.A. Masnadi-Shirazi // 2008 International Symposium on Information Technology 2008 International Symposium on Information Technology. – 2008. – T. 4. – C. 1-6.
17. Smyl S. A hybrid method of exponential smoothing and recurrent neural networks for time series forecasting : M4 Competition / S. Smyl // International Journal of Forecasting. – 2020. – Vol. 36. – № 1. – P. 75-85.
18. Oliveira E.M. de. Forecasting mid-long term electric energy consumption through bagging ARIMA and exponential smoothing methods / E.M. de Oliveira, F.L. Cyrino Oliveira // Energy. – 2018. – Vol. 144. – № C. – P. 776-788.
19. Optimized Configuration of Exponential Smoothing and Extreme Learning Machine for Traffic Flow Forecasting / H. Yang [и др.] // IEEE Transactions on Industrial Informatics. – 2019. – T. 15. – № 1. – C. 23-34.

20. Mahajan S. Short-Term PM2.5 Forecasting Using Exponential Smoothing Method: A Comparative Analysis / S. Mahajan, L.-J. Chen, T.-C. Tsai // Sensors. – 2018. – Vol. 18. – Short-Term PM2.5 Forecasting Using Exponential Smoothing Method. – № 10. – P. 3223.
21. Krogh A. What are artificial neural networks? / A. Krogh // Nature biotechnology. – 2008. – T. 26. – C. 195-7.
22. Short-term traffic forecasting using self-adjusting k-nearest neighbours / B. Sun [et al.] // IET Intelligent Transport Systems. – 2018. – Vol. 12. – № 1. – P. 41-48.
23. Dogru N. Traffic accident detection using random forest classifier / N. Dogru, A. Subasi // 2018 15th Learning and Technology Conference (L T) 2018 15th Learning and Technology Conference (L T). – 2018. – C. 40-45.
24. Gundale M.A.S. SOA based IOT framework for early detection of sensor failure / M.A.S. Gundale, D.V. Meshram // Journal of Critical Reviews. – 2020. – T. 7. – № 15. – C. 5997-6003.
25. Grus J. Data Science from Scratch / J. Grus. – 2015.
26. Бехер С.А. Способ обнаружения дефектов поверхности катания колес железнодорожных транспортных средств в движении / С.А. Бехер, Л.Н. Степанова, А.С. Кочетков. – 2013.
27. Шебякин О.С. Указания по устройству и конструкции мостового полотна на железнодорожных мостах / О.С. Шебякин, Б.А. Новиков, М.И. Гришина. – 1987.
28. Технические требования и нормы содержания железнодорожных путей промышленного транспорта / А.Г. Кузнецов [и др.]. – 2003.
29. Архивы погоды в 243 странах мира [Электронный ресурс]. – URL: <https://rp5.ru> (дата обращения: 01.06.2021).
30. Unbalanced breast cancer data classification using novel fitness functions in genetic programming / D. Devarriya [et al.] // Expert Systems with Applications. – 2020. – Vol. 140. – P. 112866.

31. Fotouhi S. A comprehensive data level analysis for cancer diagnosis on imbalanced data / S. Fotouhi, S. Asadi, M.W. Kattan // Journal of Biomedical Informatics. – 2019. – Vol. 90. – P. 103089.